

Inferencia Estadística - Básica

LuisMBaezCo

I. INFERENCIA CLÁSICA (*Paramétrica*)

- Modelos probabilísticos Paramétricos
- Teorema de Límite central
- Supuestos de Normalidad

II. INFERENCIA NO PARAMÉTRICA

- Modelos probabilísticos No-Paramétricos
- Métodos Numéricos
- Teorema de Límite central

III. INFERENCIA BAYESIANA

- Teorema de Bayes
- Técnicas de simulación Estadística (*MCMC*)
- Teorema de Límite central

IV. MUESTRA: (μ)

$\emptyset \subseteq \mu \subseteq U$
 $\emptyset : \rightarrow$ Vacío,
 $U : \rightarrow$ Población.

Muestra : $x_1, x_2, x_3, \dots, x_n$

n : Tamaño de la muestra

V. CARACTERÍSTICAS DE LA MUESTRA

- Los elementos de la población deben ser conocidos, identificables y ubicables (*Censo*)
- Se deben caracterizar la muestra.
- Todos los elementos de la población deben tener una probabilidad de ser escogidos.
- Mecanismo de la selección: (*Sorteo*)

VI. INFERENCIA CLÁSICA

Muestra : $x_1, x_2, x_3, \dots, x_n$

$X_1, X_2, X_3, \dots, X_n \rightarrow$ Variables Aleatorias.

- **Estimador** $\tilde{\theta} = \tilde{\theta}(X_1, X_2, X_3, \dots, X_n)$

Se define como una función sobre la muestra probabilística.

EJ: $\sum \frac{x_i}{n}$: Mediana $x_1, x_2, x_3, \dots, x_n$: $\sum \frac{|x_i - \bar{x}|}{n}$;

$e^{-\sum |x_i|}$

$\tilde{\theta}$ = Variable Aleatoria y tiene una función de densidad de probabilidad $f(\theta)$.

Estimación:

Es la realización de la muestra a través del estimador visto como fórmula matemática $\theta = \theta(x_1, x_2, x_3, \dots, x_n)$ con $x_1, x_2, x_3, \dots, x_n \rightarrow$ Muestras

Variabilidad:

Buen Estimador

- 1) **Insesgamiento** : $E[\tilde{\theta}] = \theta$ Si y solo si $\tilde{\theta}$ es insesgada
 $\tilde{\theta}$ estimador con sesgo si y solo si $E[\tilde{\theta}] \neq \theta$ y se aquí $b(\tilde{\theta}) = |E[\tilde{\theta}] - \theta|$

b: Sesgo

- 2) **Minima Varianza**: Si $\tilde{\theta}$ es estimador de mínima varianza si y solo si $\tilde{\theta}^*$ es otro estimador para θ entonces.

$$Var[\theta] \leq Var[\tilde{\theta}^*]$$

- 3) **Consistencia**: $\tilde{\theta}$ es consistente si y solo si $\lim_{h \rightarrow \infty} E[|\tilde{\theta}_n - \theta|] = 0$

- 4) **Suficiencia** $\tilde{\theta}$ es suficiente si y solo si la muestra tiene "la carga informativa" para alcanzar una buena estimación.

- 5) **Eficiencia** $\tilde{\theta}$ Es eficiente si y solo si para otra $\tilde{\theta}^*$ que estima θ :

$$\lim_{h \rightarrow \infty} \frac{Var[\tilde{\theta}_n]}{Var[\tilde{\theta}_n^*]} = 0$$

- ¿Cómo obtener buenos estimadores?

Las dos técnicas más usadas son las siguientes:

- 1) Estimadores por momentos
- 2) Estimadores por máxima verosimilitud

- **Estimadores por Momento:**

Momento de una Variable Aleatoria:

El r -ésimo momento de X v.a. se define como $E[x^r]$ Donde r es entero positivo.

$E[x] \rightarrow$ Valor Esperado
 $E[x^2] \rightarrow$ Varianza
 $E[x^3] \rightarrow$ Simetria
 $E[x^4] \rightarrow$ Forma

... ..

... ..

... ..

$x_1, x_2, x_3, \dots, x_n \rightarrow$ Muestras Aleatorias

$$E[x^r] \approx \frac{\sum_{i=1}^n x_i^r}{n}$$

• Estimador por Maxima Verosimilitud

Función de Verosimilitud :

$x_1, x_2, x_3, \dots, x_n$

Discreta

$x_i \sim P(x_i; \theta)$

$L(\theta / x_1, x_2, x_3, \dots, x_n) = \prod_{i=1}^n P(x_i; \theta)$

Continua

$x_i \sim f(x_i; \theta)$

$L(\theta / x_1, x_2, x_3, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$

$EMV[\tilde{\theta}]$ = Es la función que maximiza la función de verosimilitud.

• Variabilidad (Error Estándar)

Si $\tilde{\theta}$ es estimador de θ entonces $\sqrt{Var[\tilde{\theta}]}$ es la variabilidad del estimador y la estimación de $\sqrt{Var[\tilde{\theta}]}$ es conocido como "ERROR ESTÁNDAR" \rightarrow y se nota como *Desviación estandar del $st(\tilde{\theta})$*

• Teorema

Si $x_1, x_2, x_3, \dots, x_n$ es una muestra probabilística y

$$\tilde{\theta} = \frac{\sum_{i=1}^n x_i}{n}$$

$$\text{Entonces } st(\tilde{\theta}) = \frac{\sqrt{Var[x]}}{\sqrt{n}}$$

Estimación Puntual La estimación puntual es estimación y variabilidad.

• Confianza y Error

Intervalo de Confianza $I_0 : (a \leq \theta \leq b)$ es de confianza y de nivel $1 - \alpha$ si y solo si $P[I_0] = 1 - \alpha$ de tal que $1 - \alpha$ este cercano a 1 y la longitud de intervalo sea lo minimo posible.

α : Nivel de Significancia

$0 < \alpha < 1$

$100 \cdot (1 - \alpha) \%$ Nivel de confianza en porcentaje

Nota: El nivel de confianza uno lo establece

• Error

Esta ligado con la longitud del intervalo de confianza

VII. TEOREMA DEL LIMITE CENTRAL

(1) Sean $X_1, X_2, X_3, \dots, X_n$ Variables Aleatorias suficientemente grandes ($n \rightarrow \infty$)

Con $E[X_i] = \mu$ y $Var[X_i] = \sigma^2$ Entonces:

$$\bar{x} = \frac{\sum x_i}{n} \text{ Asintoticamente } N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

$$T = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

1) Si $x_1, x_2, x_3, \dots, x_n$ muestras Normales $x_i \sim N(\mu, \sigma^2)$

Si σ Es Conocida, el mejor estimador para μ es:

$$\mu(x_1, x_2, x_3, \dots, x_n) = \bar{x} = \frac{\sum x_i}{n}$$

$$st(\bar{\mu}) = \frac{\sigma}{\sqrt{n}}$$

2) Si σ es desconocida el mejor estimador para μ es :

$$\mu(x_1, x_2, x_3, \dots, x_n) = \bar{x} \text{ y}$$

$$\sigma^2 = S^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Nota: Este estimador solo se usa en inferencia para modelos normales, cuando la varianza es desconocida.

S^2 : Varianza Inssegada

$$\sigma = S = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}} \rightarrow \text{Desviación Estandar Inssegada.}$$

... ..

$$T = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \sim T_{n-1}$$

T_{n-1} : T-students con $n - 1$ grados de libertad.

$$\left[\frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \right]^2 = \frac{(n-1) \cdot S^2}{\sigma^2} \sim \chi^2_{n-1}$$

χ^2_{n-1} : Chi-cuadrado con n-1 grados de libertad.

• Teorema

Si $x_1, x_2, x_3, \dots, x_n$ es una muestra normal
 $x : \sim N(\mu, \sigma^2)$

Entonces:

$$\bar{x} = \frac{\sum x_i}{n} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Percentil Probabilístico

x_α es el percentil de nivel α si y solo si $P[x \leq x_\alpha] = \alpha$

Z_β : Percentil de nivel β de la Normal Estandar

$T_{\beta;n-1}$: Percentil de nivel β de la T-student con $n - 1$ grados de libertad

$X_{\beta;n-1}^2$: Percentil de nivel β de la chi-cuadrada con $n - 1$ grados de libertad

$f_{\beta;n-1;m-1}$: Percentil de nivel β x^2 con $n - 1$ Grado de libertad y $m - 1$ grado de libertad.

Supuestos de Normalidad (*Bajo Normalidad*)

- 1) La muestra sea Normal
- 2) Si la muestra no es Normal pero por Teorema de Limite Central se lleva a la Normalidad
- 3) Si la muestra no es Normal y no funciona el teorema de limite central, entonces se asume como normal.

Prueba de Hipótesis

Paso a paso de prueba de Hipotesis

- 1) *Plantear Hipotesis*

H_0 : Hipotesis Nula \rightarrow lo que voy a poner a prueba

θ_0 = Cuantifica la hipotesis.

H_A : Hipotesis Alternativa \rightarrow en caso de haber rechazado la hipotesis Nula y es la Negación de **H_0** .

$H_A = -H_0$

- 2) Establece un Nivel de Confianza $100 \cdot (1 - \alpha) \cdot \%$

Error: $\alpha \rightarrow$ Error tipo 1

- 3) Tener una Muestra.

$$x_1, x_2, x_3, \dots, x_n$$

- 4) Estadístico de Prueba.

$$T(x_1, x_2, x_3, \dots, x_n; \theta_0)$$

- 5) Punto Critico

$$t_0 = t(x_1, x_2, x_3, \dots, x_n; \theta_0)$$

- 6) Criterio de Decisión

H_0 : Se rechaza si y solo si $P[T \geq t_0] < \alpha$

- Equivalente

I) Uso de Percentil

II) **H_0** se rechaza si y solo si

θ_0 No esta en el intervalo de confianza asociado

III) P-valor es una estimación $P[T \geq t_0]$ **H_0** se rechaza si y solo si $(p - \text{valor} < \alpha)$

- 7) Respuesta

VIII. INTERVALOS DE CONFIANZA

¿Que uno busc de la Inferencia Estadística?

- 1) **Estimación:** Estimación es para $\mu : \bar{x}$

- 2) **Variabilidad:** (Error Estandar) $\frac{S}{\sqrt{n}}$

- 3) **Confianza:** $100 \cdot (1 - \alpha) \%$

- 4) **Error:** $T_{\frac{\alpha}{2}; n-1} \cdot \frac{S}{\sqrt{n}}$

- **Intervalo de Confianza para $x \sim N(\mu, \sigma)$ Poblacional con μ y σ Conocidas, para $IC_{95\%}$**

$$p[x \leq x_0] = 0.95 \quad \alpha = 1 - 0.95 = 0.05$$

$$0.95 + \frac{\alpha}{2} = 0.95 + \frac{0.05}{2} = 0.975$$

$$p\left[z \leq \frac{x_0 - \mu}{\sigma}\right] = 0.975$$

$$\frac{x_0 - \mu}{\sigma} = 1.96$$

$$x_1 = -1.96 \cdot \sigma + \mu$$

$$x_2 = 1.96 \cdot \sigma + \mu$$

$$IC_{95\%} = (x_1; x_2)$$

- **Intervalo de Confianza para μ con Varianza Desconocida**

$x_1, x_2, x_3, \dots, x_n$ Muestras.

$$IC_{\%} = \left(\bar{x} - T_{\frac{\alpha}{2}; n-1} \cdot \frac{S}{\sqrt{n}}; \bar{x} + T_{\frac{\alpha}{2}; n-1} \cdot \frac{S}{\sqrt{n}} \right) \quad (2)$$

$(\bar{x} - \epsilon, \bar{x} + \epsilon)$ Donde *epsilon*: Error.

Confianza del $100 \cdot (1 - \alpha) \%$

$$T_{n-1} \sim \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}$$

$$T = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}; T_0 = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}} \quad T_0 = \text{Punto Critico}$$

$$\mu = \bar{x} - \frac{T \cdot S}{\sqrt{n}}$$

Prueba de Hipotesis

$$H_0: \mu = \mu_0$$

$$H_A: \mu \neq \mu_0$$

$$T = \frac{\bar{x} - \mu_0}{\frac{S}{\sqrt{n}}}$$

$$t_0 = \frac{\bar{x} - \mu_0}{\frac{S}{\sqrt{n}}} \text{ Punto Critico.}$$

Criterio de Decisión

-Intervalo de Confianza:

H0 se Rechaza si y solo si μ_0 no esta en el intervalo de confianza.

-Percentil:

H0 se rechaza si y solo si

$$|t_0| \geq T_{\frac{\alpha}{2}; n-1}$$

• Intervalo de Confianza para la Varianza

$x_1, x_2, x_3, \dots, x_n$ Muestra Normal.

$$IC\% = \left(\frac{(n-1) \cdot S^2}{X_{\frac{\alpha}{2}; n-1}^2}; \frac{(n-1) \cdot S^2}{X_{1-\frac{\alpha}{2}; n-1}^2} \right) \quad (3)$$

• Intervalo de Confianza para la Proporción (r)

$x_1, x_2, x_3, \dots, x_n$ Bernoulli.

y bajo supuestos de normalidad.

$$\hat{r} = \frac{\text{Numero de Casos Favorables}}{\text{Numero de Casos Posibles}} \quad (4)$$

$$IC\% = \left(\hat{r} - Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{r} \cdot (1-\hat{r})}{n}}; \hat{r} + Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{r} \cdot (1-\hat{r})}{n}} \right) \quad (5)$$

Confianza del $100 \cdot (1 - \alpha) \%$

Prueba de Hipotesis

$$H_0: r = r_0$$

$$H_A: r \neq r_0$$

$$z = \frac{r - r_0}{\sqrt{\frac{r \cdot (1-r)}{n}}}$$

$$z_0 = \frac{\hat{r} - r_0}{\sqrt{\frac{\hat{r} \cdot (1-\hat{r})}{n}}}$$

Criterio de Decisión

H0 se Rechaza si y solo si

$$|z_0| \geq Z_{1-\frac{\alpha}{2}}$$

• Intervalo de Confianza para μ con Varianza Conocida

$$IC\% = \left(\bar{x} - Z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + Z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \right) \quad (6)$$

$$z = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

Prueba de Hipotesis

$$H_0: \mu = \mu_0$$

$$H_A: \mu \neq \mu_0$$

$$z_0 = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

Criterio de Decisión

H0: se rechaza si y solo si

$$|z_0| \geq Z_{1-\frac{\alpha}{2}}$$

IX. INTERVALO DE CONFIANZA PARA COMPARAR MEDIAS

$x_1, x_2, x_3, \dots, x_n$ Bajo Normalidad.

$$\bar{x} \sim N\left(\mu_x, \frac{\sigma_x^2}{n}\right)$$

$y_1, y_2, y_3, \dots, y_n$ Bajo Normalidad.

$$\bar{y} \sim N\left(\mu_y, \frac{\sigma_y^2}{n}\right)$$

$$\mu_x = \mu_y \equiv \mu_x - \mu_y = 0$$

$$\mu_x > \mu_y \equiv \mu_x - \mu_y > 0$$

$$\mu_x < \mu_y \equiv \mu_x - \mu_y < 0$$

• Intervalo de Confianza para Comparar Medias con Varianza Conocida

σ_x^2 y σ_y^2 Son Conocidas.

$$IC\% = \left((\bar{x} - \bar{y}) - Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\sigma_x^2}{n} + \frac{\sigma_y^2}{m}} \right) \quad (7)$$

$$\left(; (\bar{x} - \bar{y}) + Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\sigma_x^2}{n} + \frac{\sigma_y^2}{m}} \right) \quad (8)$$

Nota: El resultado es el rango de diferencias de las medias.

Si ($result_x < 0$; $result_y > 0$) o viceversa: *Las Medias son Iguales* $\mu_x = \mu_y$

Si ($result_x > 0$; $result_y > 0$) Entonces $\mu_x > \mu_y$

Si ($result_x < 0$; $result_y < 0$) Entonces $\mu_x < \mu_y$

Prueba de Hipotesis

H₀: $\mu_x - \mu_y = \delta_0$

H_A: $\mu_x - \mu_y \neq \delta_0$

$$z_0 = \frac{(\bar{x} - \bar{y}) - \delta_0}{\sqrt{\frac{\sigma_x^2}{n} + \frac{\sigma_y^2}{m}}}$$

Criterio de Decisión

H₀: se Rechaza si y solo si

$$|z_0| \geq Z_{1-\frac{\alpha}{2}}$$

- **Intervalo de Confianza para Comparar Medias con Varianza Desconocida pero Iguales**

σ_x^2 y σ_y^2 Son Desconocidas.

Pero $\sigma_x^2 = \sigma_y^2$

$$IC\% = \left((\bar{x} - \bar{y}) - T_{\frac{\alpha}{2}; n+m-2} \cdot SP \cdot \sqrt{\frac{1}{n} + \frac{1}{m}} \right) \quad (9)$$

$$\left(; (\bar{x} - \bar{y}) + T_{\frac{\alpha}{2}; n+m-2} \cdot SP \cdot \sqrt{\frac{1}{n} + \frac{1}{m}} \right) \quad (10)$$

$$SP = \sqrt{\frac{(n-1) \cdot S_x^2 + (m-1) \cdot S_y^2}{n+m-2}} \quad (11)$$

Si ($result_x < 0$; $result_y > 0$) o viceversa: *Las Medias son Iguales* $\mu_x = \mu_y$

Si ($result_x > 0$; $result_y > 0$) Entonces $\mu_x > \mu_y$

Si ($result_x < 0$; $result_y < 0$) Entonces $\mu_x < \mu_y$

Prueba de Hipotesis

H₀: $\mu_x - \mu_y = \delta_0$

H_A: $\mu_x - \mu_y \neq \delta_0$

$$t_0 = \frac{(\bar{x} - \bar{y}) - \delta_0}{SP \cdot \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

Criterio de Decisión

$$|t_0| \geq T_{\frac{\alpha}{2}; n+m-2}$$

- **Intervalo de confianza para Comparar Medias para Datos Emparejados**

$x :$ $x_1, x_2, x_3, \dots, x_n$

$y :$ $y_1, y_2, y_3, \dots, y_n$

Diferencia:

$$d_1 = x_1 - y_1$$

$$d_2 = x_2 - y_2$$

... ..

$$d_n = x_n - y_n$$

Nota: El intervalo de confianza gira en torno a d

$$IC\% = \left(\bar{d} - T_{\frac{\alpha}{2}; n-1} \cdot \frac{Sd}{\sqrt{n}}; \bar{d} + T_{\frac{\alpha}{2}; n-1} \cdot \frac{Sd}{\sqrt{n}} \right) \quad (12)$$

Sd = Desviacion Estandar Muestral de las Diferencias

μ_d : **Media de la Diferencia.**

$$\mu_d = \mu_x - \mu_y$$

Si 0 esta dentro del intervalo se puede concluir que no mejoró.

- **Intervalo de Confianza para comparar Proporciones**

r_1 y r_2

$$IC\% = x_0 \left((\hat{r}_1 - \hat{r}_2) - Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{r}_1 \cdot (1 - \hat{r}_1)}{n} - \frac{\hat{r}_2 \cdot (1 - \hat{r}_2)}{m}} \right) \quad (13)$$

$$y_0 \left((\hat{r}_1 - \hat{r}_2) + Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{r}_1 \cdot (1 - \hat{r}_1)}{n} - \frac{\hat{r}_2 \cdot (1 - \hat{r}_2)}{m}} \right) \quad (14)$$